



K-Nearest neighbor (KNN)

K-Nearest Neighbors (KNN) คือ อัลกอริทึมประเภท Supervised Learning ที่ใช้สำหรับทำนายกลุ่มข้อมูลหรือการจำแนกประเภท (Classification) และการพยากรณ์ค่าต่อเนื่อง (Regression) โดยใช้หลักการวัดระยะความใกล้เคียงของข้อมูลใหม่กับข้อมูลเดิมที่มีอยู่ (Training Data) เพื่อหาเพื่อนบ้านที่ใกล้ที่สุดจำนวน K ตัว



หลักการทำงานของ KNN

1. กำหนดค่า K

เลือกจำนวนเพื่อนบ้านใกล้ที่สุด เช่น $K=3$ หรือ $K=5$ (นิยมใช้เลขคี่เพื่อป้องกันผลโหวตเสมอ)

2. วัดระยะทาง

คำนวณระยะห่างระหว่างข้อมูลใหม่กับข้อมูลทั้งหมดในระบบด้วยสูตรวัดระยะ เช่น Euclidean Distance

3. คัดเลือกเพื่อนบ้าน

เรียงลำดับระยะทางจากน้อยไปมาก แล้วเลือกข้อมูลที่มีระยะใกล้ที่สุดตามจำนวน $\lfloor K/2 \rfloor$ ที่ตั้งไว้ [1, 2]

4. ทำนายผลลัพธ์

- กรณีจัดหมวดหมู่ (Classification) : ใช้เสียงส่วนใหญ่ ว่าเพื่อนบ้าน $\lfloor K/2 \rfloor$ ตัวอยู่กลุ่มไหนมากที่สุด ข้อมูลใหม่ก็จะเป็นกลุ่มนั้น
- กรณีทำนายค่าต่อเนื่อง (Regression) : หาค่าเฉลี่ยของตัวเลขจากเพื่อนบ้าน $\lfloor K/2 \rfloor$ ตัวนั้นมาเป็นคำตอบ

การวัดระยะทาง (Distance Metrics)

1. **Euclidean Distance** : ใช้วัดระยะห่างแบบปกติในพื้นที่ n มิติ เป็นเส้นตรงตามแนวเรขาคณิต (นิยมใช้มากที่สุด) $\therefore$

$$\begin{aligned} d(x, x_i) &= \sqrt{\sum_{j=1}^n (x_j - x_{ij})^2} \\ &= \sqrt{(x_1 - x_{i1})^2 + (x_2 - x_{i2})^2} \end{aligned}$$

2. **Manhattan Distance / L1-norm / Taxicab Distance** : ใช้คำนวณระยะห่างโดยรวม ค่าความแตกต่างสัมบูรณ์ในแต่ละมิติ เป็นระยะทางตามแนวแกนฉาก (แนวแกน x และ y เท่านั้น)

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

2. ข้อมูลใหม่ที่ต้องการทำนาย (Test Instance)

ผลไม้ปริศนา (X) : น้ำหนัก = 130 กรัม, ความขรุขระ = 6

3. ขั้นตอนการคำนวณระยะห่าง (Euclidean Distance)

- ระยะห่างจาก X ถึง A (ส้ม) :

$$\begin{aligned}d(X, A) &= \sqrt{(130 - 120)^2 + (6 - 8)^2} \\&= \sqrt{10^2 + (-2)^2} \\&= \sqrt{100 + 4} \\&= \sqrt{104} \approx 10.20\end{aligned}$$

ตัวอย่างการคำนวณ KNN (Classification)

สมมติว่าเราต้องการทำนายว่า "ผลไม้ปริศนา" คือ ส้ม หรือ แอปเปิ้ล โดยพิจารณาจาก 2 คุณลักษณะ

1.ชุดข้อมูล Training Set

จุดข้อมูล	ประเภทผลไม้	น้ำหนัก	ความขรุขระ
A	ส้ม	120	8
B	ส้ม	140	7
C	แอปเปิ้ล	170	2
D	แอปเปิ้ล	160	3

- ระยะห่างจาก X ถึง B (ส้ม):

$$\begin{aligned}d(X, B) &= \sqrt{(130 - 140)^2 + (6 - 7)^2} \\&= \sqrt{(-10)^2 + (-1)^2} \\&= \sqrt{100 + 1} \\&= \sqrt{101} \approx 10.05\end{aligned}$$

- ระยะห่างจาก X ถึง C (แอปเปิ้ล):

$$\begin{aligned}d(X, C) &= \sqrt{(130 - 170)^2 + (6 - 2)^2} \\&= \sqrt{(-40)^2 + 4^2} \\&= \sqrt{1600 + 16} \\&= \sqrt{1616} \approx 40.20\end{aligned}$$

- ระยะห่างจาก X ถึง D (แอปเปิ้ล) :

$$\begin{aligned}d(X, D) &= \sqrt{(130 - 160)^2 + (6 - 3)^2} \\&= \sqrt{(-30)^2 + 3^2} \\&= \sqrt{900 + 9} \\&= \sqrt{909} \approx 30.15\end{aligned}$$

4. สรุปผลลัพธ์และการลงมติ (Majority Voting)



เรียงลำดับระยะห่างจากน้อยไปมาก :

1. จุด B (ส้ม) : ระยะห่าง 10.05
2. จุด A (ส้ม) : ระยะห่าง 10.20
3. จุด D (แอปเปิ้ล) : ระยะห่าง 30.15
4. จุด C (แอปเปิ้ล) : ระยะห่าง 40.20




- กรณีตั้งค่า $K = 3$ (พิจารณาเพื่อนบ้านใกล้ที่สุด 3 อันดับแรก) :
 - เพื่อนบ้าน 3 อันดับแรกคือ B (ส้ม), A (ส้ม), และ D (แอปเปิ้ล)
 - ผลโหวต: ส้ม 2 เสียง vs แอปเปิ้ล 1 เสียง

ดังนั้น ผลลัพธ์ของอัลกอริทึม : อัลกอริทึม KNN จะทำนายว่า "ผลไม้ปริศนาชิ้นนี้คือ ส้ม"




Visualization



● Apple (กลุ่มแอปเปิ้ล): กลุ่มข้อมูลผลไม้ที่มีน้ำหนักค่อนข้างมาก (160–170 กรัม) และมีระดับความขรุขระของผิวต่ำ (ระดับ 2–3) ซึ่งเป็นลักษณะเฉพาะของแอปเปิ้ลผิวเรียบ

● Orange (กลุ่มส้ม): กลุ่มข้อมูลผลไม้ที่มีน้ำหนักปานกลาง (120–140 กรัม) และมีระดับความขรุขระของผิวสูง (ระดับ 7–8) ซึ่งเป็นลักษณะเฉพาะของส้มที่มีเปลือกขรุขระ

● Unknown Fruit (ผลไม้ปริศนา): ข้อมูลตำแหน่งอ้างอิงทดสอบ (น้ำหนัก 150 กรัม, ความขรุขระ 6) สำหรับทำนายผล โดยระบบคำนวณระยะทางไปยังเพื่อนบ้านใกล้ที่สุด $K = 3$ ลำดับ และจัดอยู่ในกลุ่มแอปเปิ้ลตามเสียงส่วนใหญ่




K-NEAREST NEIGHBORS REGRESSION (KNN REGRESSION)



การทำนายค่าต่อเนื่องด้วยอัลกอริทึมเพื่อนบ้านใกล้ที่สุด K ตำแหน่ง

KNN Regression คืออะไร

- อัลกอริทึมแบบ Non-Parametric: ไม่ตั้งข้อสมมติฐานใดๆ เกี่ยวกับการกระจายตัวของชุดข้อมูล
- Instance-Based / Lazy Learning: ไม่สร้างสมการโมเดลแบบคงที่ แต่จะเก็บข้อมูลฝึกฝนไว้คำนวณขณะทำนายผล
- การทำนายค่าต่อเนื่อง: ประมาณค่าเป้าหมายเชิงตัวเลขโดยการหาค่าเฉลี่ยของเพื่อนบ้านใกล้ที่สุด K ตัว
- หลักการระยะห่าง: ทำงานบนหลักการที่ว่าจุดข้อมูลที่มีลักษณะคล้ายกันจะอยู่ใกล้กันในสเปซข้อมูล



ขั้นตอนการทำงานของ KNN Regression

- 1 กำหนดค่า K : เลือกจำนวนเพื่อนบ้านที่ต้องการพิจารณา
- 2 คำนวณระยะห่าง: วัดระยะจากจุดข้อมูลทดสอบ (Test Point) ไปยังข้อมูลสอน (Training Points) ทั้งหมด
- 3 คัดเลือก K เพื่อนบ้าน: จัดลำดับและเลือก K จุดที่มีระยะห่างสั้นที่สุด
- 4 ทำนายผลลัพธ์: นำค่าเป้าหมาย (y) ของ K เพื่อนบ้านมาหาค่าเฉลี่ยเพื่อเป็นค่าพยากรณ์



สูตรการคำนวณและคณิตศาสตร์

Euclidean Distance

การวัดระยะทางเส้นตรงมาตรฐานในสเปซยูคลิด

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Unweighted KNN Prediction

ค่าพยากรณ์คือค่าเฉลี่ยธรรมดาของ K เพื่อนบ้านที่ใกล้ที่สุด

$$\hat{y} = \frac{1}{K} \sum_{i=1}^K y_i$$



Weighted KNN Regression

แนวคิดการถ่วงน้ำหนัก

ให้ความสำคัญแก่เพื่อนบ้านที่อยู่ "ใกล้กว่า" มากกว่าเพื่อนบ้านที่อยู่ไกลออกไป เพื่อให้การทำนายมีความแม่นยำและสมจริงมากยิ่งขึ้น

การคำนวณน้ำหนัก (Weight, w):

$$w_i = \frac{1}{d(x, x_i)}$$

สูตรคำนวณ Weighted Mean

ค่าทำนายจากการถ่วงน้ำหนักด้วยส่วนกลับของระยะทาง:

$$\hat{y} = \frac{\sum_{i=1}^K w_i y_i}{\sum_{i=1}^K w_i}$$



ผลกระทบของการเลือกค่า K

K = 3

ค่าเริ่มต้นยอดนิยมในการทดสอบ

การเลือกค่า K ที่เหมาะสม (Optimal K)

- K ขนาดเล็กเกินไป (เช่น $K=1$): โมเดลไวต่อ Noise มีโอกาสเกิด Overfitting สูง ทำนายจะมีความผันผวนมาก
- K ขนาดใหญ่เกินไป (เช่น $K=N$): โมเดลเรียบเกินไป ทำนายได้เพียงค่าเฉลี่ยรวม เกิด Underfitting
- วิธีแก้ไข: ใช้ Cross-Validation ในการเลือกค่า K ที่ให้ค่าความคลาดเคลื่อนต่ำที่สุด

ตัววัดประเมินผล (Evaluation Metrics)

Mean Absolute Error (MAE): ค่าเฉลี่ยของความคลาดเคลื่อนสัมบูรณ์ วัดความผิดพลาดเฉลี่ยโดยไม่คิดทิศทาง

Root Mean Squared Error (RMSE): รากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง ให้ความสำคัญกับข้อผิดพลาดขนาดใหญ่ (Outliers)


R-squared (R^2 Score): สัดส่วนความแปรปรวนของข้อมูลที่ไม่ได้อธิบายได้ มีค่าตั้งแต่ 0 ถึง 1 (ยิ่งใกล้ 1 ยิ่งแม่นยำ)


Visualization

กราฟ Scatter Plot: แสดงจุดข้อมูลฝึกสอน (Training Points) เป็นจุดกระจายตัว


เส้นทำนาย (Regression Curve): วาดเส้นแสดงค่าทำนายตามช่วงข้อมูล จะเห็นลักษณะเป็น Step-wise function

แสดงจุดทดสอบ (Test Point): ลากเส้นเชื่อมไปยัง K เพื่อนบ้านที่ใกล้ที่สุด เพื่อให้ผู้อ่านเข้าใจกระบวนการคำนวณได้อย่างชัดเจน





Machine Learning





K-Means Clustering


จากทฤษฎีคณิตศาสตร์สู่การประยุกต์ใช้จริง

การวิเคราะห์หลักของอัลกอริทึม การคำนวณทางคณิตศาสตร์ และการต่อยอดสู่กลยุทธ์ธุรกิจ

ข้อมูลดิบ (Unlabelled Data) - ไม่มีการกำหนดป้ายกำกับ



ข้อมูลที่ถูกจัดกลุ่ม (Labelled Clusters)



กลไกพื้นฐานของ K-Means

อัลกอริทึมประเภท Instance-based Unsupervised Learning และ Partitioning Algorithm ที่กำหนดที่แบ่งข้อมูลออกเป็น K กลุ่ม โดยอาศัยความใกล้เคียงของข้อมูลกับ 'จุดศูนย์กลางกลุ่ม' (Centroid)

เป้าหมาย: จัดกลุ่มข้อมูลที่มีลักษณะคล้ายกันให้อยู่ด้วยกัน และแยกข้อมูลที่แตกต่างกันออกจากกันอย่างชัดเจน

จุดเด่นและมิติการประยุกต์ใช้งาน (Exploratory Data Analysis)

No Labels Needed: รวดเร็วและรองรับข้อมูลขนาดใหญ่ ทำงานได้ทันทีโดยไม่ต้องใช้ข้อมูลที่มี Label ช่วยให้เข้าใจโครงสร้างข้อมูลได้อย่างรวดเร็ว

High Efficiency: ทำงานได้อย่างรวดเร็วและมีประสิทธิภาพสูงกับชุดข้อมูลขนาดใหญ่

Simplicity: มีโครงสร้างและขั้นตอนการทำงานที่ทำความเข้าใจและนำไปประยุกต์ใช้ได้ง่าย

Marketing

การแบ่งกลุ่มกลุ่มลูกค้าเพื่อวางกลยุทธ์การตลาด

Education

การจัดกลุ่มนักเรียนหรือนักศึกษาตามผลการเรียนเพื่อพัฒนาอย่างตรงจุด

Technology


การจัดกลุ่มไฟล์ข่าว เอกสาร หรือรูปภาพที่มีความคล้ายคลึงกัน

กลไกการทำงาน: อาศัยระยะทางและค่าเฉลี่ย

Euclidean Distance
(การวัดความไกลเคียง)

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

ใช้คำนวณระยะห่าง
ระหว่างจุดข้อมูลกับจุด
Centroid



Mean Calculation
(การหาจุดศูนย์กลางใหม่)

$$\bar{x} = \frac{\sum x}{n}, \quad \bar{y} = \frac{\sum y}{n}$$

ใช้ปรับตำแหน่ง Centroid
ให้เคลื่อนเข้าหา
จุดศูนย์กลางที่แท้จริงของ
กลุ่ม

5 ขั้นตอนการทำงานของ K-Means (The Iterative Cycle)

การตั้งค่าเริ่มต้น (Initialization)

Step 1:

กำหนดจำนวนกลุ่ม (K)
ระบุจำนวนกลุ่มข้อมูลที่ต้องการจัดแบ่งอย่างเหมาะสม




Step 2:

กำหนดจุดศูนย์กลางเริ่มต้น (Initial Centroids) แบบสุ่ม
สุ่มเลือกจุดข้อมูลจำนวน K จุด เพื่อเป็นพิกัดเริ่มต้นของศูนย์กลางกลุ่ม

วงล้อการปรับแต่ง (Iterative Loop)

Step 3: จัดข้อมูลเข้ากลุ่ม (Cluster Assignment)

ดึงข้อมูลเข้าหา Centroid ที่ใกล้ที่สุดด้วย Euclidean Distance



Step 4: คำนวณหา Centroid ใหม่ (Update Centroid)

คำนวณค่าเฉลี่ยพิกัด (Mean) ของจุดข้อมูลทั้งหมดที่สังกัดอยู่ในแต่ละกลุ่มเพื่อเป็นพิกัดศูนย์กลางใหม่

Step 5: ทำซ้ำ (Iteration)

ย้อนทำขั้นตอนที่ 3 และ 4 ซ้ำจนกระทั่งค่าจุดศูนย์กลางไม่มีการเปลี่ยนแปลงอีกต่อไป (Convergence) หรือทำงานครบรอบสูงสุดที่กำหนด


การพิสูจน์ทางคณิตศาสตร์: กำหนดจุดข้อมูลและพิกัดเริ่มต้น

จุดข้อมูลดิบ (Data Points)

ชุดข้อมูลจำลองและจุดศูนย์กลางเริ่มต้น

ข้อมูลพิกัด 2 มิติ (มิติ X, Y) จำนวน 6 จุด

A(2, 3), B(3, 4), C(4, 5), D(8, 8), E(9, 9), F(8, 10)




การตั้งค่าเริ่มต้น (Initialization)

Step 1: กำหนด $K = 2$ (แบ่งเป็น 2 กลุ่ม)

Step 2: กำหนด Initial Centroids:

Centroid 1 เริ่มต้น (c_1): พิกัดเดียวกับจุด A คือ (2, 3)

Centroid 2 เริ่มต้น (c_2): พิกัดเดียวกับจุด E คือ (9, 9)



การคำนวณระยะทางแบบละเอียด (Euclidean Distance)

จุดข้อมูล	ระยะถึง $C_1(2, 3)$	ระยะถึง $C_2(9, 9)$
A (2, 3)	$\sqrt{(2-2)^2 + (3-3)^2} = 0.00$	$\sqrt{(2-9)^2 + (3-9)^2} = 9.22$
B (3, 4)	$\sqrt{(3-2)^2 + (4-3)^2} = 1.41$	$\sqrt{(3-9)^2 + (4-9)^2} = 7.81$
C (4, 5)	$\sqrt{(4-2)^2 + (5-3)^2} = 2.83$	$\sqrt{(4-9)^2 + (5-9)^2} = 6.40$
D (8, 8)	$\sqrt{(8-2)^2 + (8-3)^2} = 7.81$	$\sqrt{(8-9)^2 + (8-9)^2} = 1.41$
E (9, 9)	$\sqrt{(9-2)^2 + (9-3)^2} = 9.22$	$\sqrt{(9-9)^2 + (9-9)^2} = 0.00$
F (8, 10)	$\sqrt{(8-2)^2 + (10-3)^2} = 9.22$	$\sqrt{(8-9)^2 + (10-9)^2} = 1.41$

การหาจุดศูนย์กลางเฉลี่ยของกลุ่ม (Iteration 1)


กลุ่มที่ 1 ใกล้ C_1

A (2,3), B (3,4), C (4,5)

กลุ่มที่ 2 ใกล้ C_2

D (8,8), E (9,9), F (8,10)

Step 3: Cluster Assignment Result (Round 1)



หมายเหตุ: ระบบทำการตัดสินใจเชิงพื้นที่เสร็จสิ้น
เตรียมเข้าสู่การปรับสมดุล (Update Centroid) ในขั้นตอนต่อไป

การคำนวณหาจุดศูนย์กลางใหม่ (Update Centroid)

$$C_1 = \left(\frac{2 + 3 + 4}{3}, \frac{3 + 4 + 5}{3} \right) = (3.00, 4.00)$$

$$\bar{x}_1 = \frac{2 + 3 + 4}{3} = 3.00$$


$$\bar{y}_1 = \frac{3 + 4 + 5}{3} = 4.00$$

$$C_2 = \left(\frac{8 + 9 + 8}{3}, \frac{8 + 9 + 10}{3} \right) = (8.33, 9.00)$$

$$\bar{x}_2 = \frac{8 + 9 + 8}{3} = 8.33$$

$$\bar{y}_2 = \frac{8 + 9 + 10}{3} = 9.00$$

Step 4: Update Centroid



หมายเหตุ: เมื่อคำนวณต่อในรอบที่ 2 ผลลัพธ์ของการจัดกลุ่มจะยังคงเหมือนเดิม ทำให้โมเดลลูเข้าหาคำตอบสุดท้ายทันที (Convergence)


Step 5: ตรวจสอบการลู่เข้าหาคำตอบ (Convergence)

- Centroid Shift: การวัดระยะทางที่ Centroid เคลื่อนที่ไปจากรอบที่แล้ว
- Stopping Criteria: อัลกอริทึมจะหยุดทำซ้ำเมื่อการเปลี่ยนแปลงของ Centroid เข้าใกล้ 0 (ลู่เข้าหาคำตอบ) หรือถึงจำนวนรอบสูงสุดที่กำหนดไว้

Plaintext

- Iteration 1: Centroid shift = 5.852528
 - Iteration 2: Centroid shift = 2.716512
 - Iteration 3: Centroid shift = 0.312264
- Iteration 4: Centroid shift = 0.000000 -> K-Means converged.


วิเคราะห์พฤติกรรมลูกค้าห้างสรรพสินค้า (Mall Customer Segmentation)



บริบททางธุรกิจ:

- Dataset: ชุดข้อมูลลูกค้า 200 ราย
- Features ที่เลือกใช้: รายได้ต่อปี และ คะแนนการใช้จ่าย
- เป้าหมาย: ค้นหารูปแบบแฝงของกลุ่มลูกค้าเพื่อออกแบบแคมเปญการตลาดที่ตรงจุด โดยให้โมเดลทำความเข้าใจข้อมูลโดยปราศจากอคติของมนุษย์

วิเคราะห์พฤติกรรมลูกค้าห้างสรรพสินค้า (Mall Customer Segmentation)



บริบททางธุรกิจ:

- Dataset: ชุดข้อมูลลูกค้า 200 ราย
- Features ที่เลือกใช้: รายได้ต่อปี และ คะแนนการใช้จ่าย
- เป้าหมาย: ค้นหารูปแบบแฝงของกลุ่มลูกค้าเพื่อออกแบบแคมเปญการตลาดที่ตรงจุด โดยให้โมเดลทำความเข้าใจข้อมูลโดยปราศจากอคติของมนุษย์

วิเคราะห์พฤติกรรมลูกค้าห้างสรรพสินค้า (Mall Customer Segmentation)

กลุ่มประหยัด (Cluster 1)

- สภาวะ: รายได้น้อย - ใช้จ่ายต่ำ
- คำอธิบาย: ลูกค้าที่มีกำลังซื้อน้อยหรือระมัดระวังการใช้จ่าย
- กลยุทธ์: เน้นโปรโมชั่นคูปองส่วนลด หรือสินค้าที่เน้นความคุ้มค่า (Value for Money)

ลูกค้าทั่วไป (Cluster 2)

- สภาวะ: รายได้ปานกลาง - ใช้จ่ายปานกลาง
- คำอธิบาย: ฐานลูกค้าหลักที่มีพฤติกรรมสม่ำเสมอ
- กลยุทธ์: รักษาความสัมพันธ์ (Retention), แนะนำสินค้าใหม่ที่เข้ากับไลฟ์สไตล์

ลูกค้ามูลค่าสูง (Cluster 3)

- สภาวะ: รายได้สูง - ใช้จ่ายสูง
- คำอธิบาย: High Value Customers พร้อมจ่ายเพื่อประสบการณ์
- กลยุทธ์: สินค้า Premium, บริการ Exclusive, และโปรแกรมสมาชิกชั้นสูง (Loyalty Programs)

สมาชิกกลุ่ม

1. 67011211070 นางสาวจิตติมา คำแก้ว
2. 67011211091 นายศิริศิลป์ คงสีดา
3. 67011211093 นายอศิราภ์ เข้มทอง
4. 67011211133 นางสาววิภา ฆาระกุล
5. 67011211136 นายเศวตโชติ พอกพูน